

2024-2025 年第 2 学期



南京信息工程大学

机器学习平台及其应用实战

授课教师：吴高峰

课程报告

得分：	
-----	--

学 号：	202283250057
姓 名：	王玉茹
班 级：	22 大数据 2 班
提交时间：	2025 年 6 月 26 日

目录

1 任务背景及需求分析	3
1.1 任务背景	3
1.2 需求分析	3
2 数据及预处理	4
2.1 分类削减数据集	4
2.2 数据归一化结构调整	4
2.3 部分数据集可视化	5
3 模型选择	6
3.1 卷积神经网络 CNN	6
3.2 生成对抗网络 GAN	6
3.3 卷积门控循环单元 ConvGRU	6
4 建模与实现	7
4.1 Softmax 约束层的设计	7
4.2 CNN 的实现	7
4.3 GAN 的实现	8
4.4 ConvGRU 的实现	8
5 训练测试	8
5.1 实验设计	8
5.2 训练评估流程	9
6 结果与分析	10
6.1 约束对 CNN 的影响分析	10
6.2 约束对 ConvGRU 的影响分析	11
6.3 约束对 GAN 的影响分析	12
6.4 约束对 FlowConvGRU 的影响分析	12
7 结论	13
8 附录	14

1 任务背景及需求分析

1.1 任务背景

图像超分辨率（Super-Resolution）指从低分辨率图像重建高分辨率图像的技术，可以显著提升图像的清晰度和细节。该技术在众多领域发挥着重要作用，如提升监控视频的辨识度、增强医学影像的细节，以及改善卫星遥感图像的清晰度和精度等。遥感图像的数据通常具有实际的物理意义，比如卫星观测的某地区的总柱水量（Total Column Water, TCW）数据集的图像像素代表该地区对应位置地表正上方大气柱中的水汽总质量。这类气象数据受限于较低的空间分辨率和有限精度，导致细节信息不足，难以满足精细气象分析的需求。通过引入超分辨率方法对这类气象数据进行降尺度，可以部分弥补分辨率不足，增强气象遥感数据的细节质量，以进行天气预报、灾害预警等实际应用，具有宝贵的现实意义。




图 1 气象场降尺度示意图

1.2 需求分析

气象数据降尺度的核心并不是和图像超分辨一样“让图像看起来更清楚”；它要求在符合自然规律和满足物理可靠性的前提下，提升气象数据的空间分辨率，从而用于更精细的气象分析、洪水预估、对流判识等实际应用。在无物理约束的深度降尺度模型中，预测结果易出现质量不守恒或非物理值的问题，比如用一般的深度学习降尺度模型会产生一些不可解释的负值像素或者凭空产生多余水汽的现象。实际降尺度应用中，这类不守恒性会严重影响下游应用的准确性：例如降水场的总量若不守恒，将导致径流和水量平衡估算出现误差。为此，需要在网络设计中加入物理一致性约束层的设计，在输出端限制预测值，确保降尺度的结果符合基础的物理规律。一种常用方法是使用规范化层对输出进行重标度。

本次实践验证通过加入 Softmax 守恒约束层的各种深度学习降尺度模型的输出更加符合物理规律，输出的降尺度结果更具有可信度。

2 数据及预处理

本次实践采用的是塔塞尔帽湿度数据集（TCW），包含配对的低分辨率（LR）和高分辨率（HR）影像，数据集被划分为“单帧静态图像对”和“多帧时序图像序列”两类。原始数据集总样本数达到 40000，考虑到训练效率和算力资源限制，本次实践对数据集进行了有针对性的缩减和预处理。

2.1 分类削减数据集

原始数据集根据时序特征划分为静态图像对（如 TCW2、TCW4、TCW8）和时序图像序列（T1），前者用于基础的超分辨率模型训练（CNN、GAN 等），后者适配具备时间建模能力的模型（如 ConvGRU）。为平衡训练成本与模型覆盖，本次实践分别在两类数据集中各抽取若干子集作为代表，构建训练集与验证集。其中静态图像数据从每个尺度级别中选取 1024 对训练集图像，300 对验证集图像；时序数据选取长度为 3 的连续图像序列，训练集和验证集分别 300 组。

2.2 数据归一化结构调整

为适配深度学习框架训练需求，把原始遥感图像转化成 torch.Tensor 格式，并按 [N, T, C, H, W] 的五维结构标准化存储。此外，所有像素值均进行了归一化处理（线性缩放至 0~100 区间），以保证各尺度数据分布一致，防止训练中出现梯度不稳定问题。完成结构整理与归一化后，数据以 PyTorch 的.pt 二进制格式序列化保存。该格式可直接存储张量结构，支持高效加载与 GPU 并行计算，便于在模型训练与验证阶段快速读取。最终得到的训练集结构如下表 1 所示。

表 1 数据集说明

名称	上采样倍数	数据集维度（train/val）	特征说明
T1	4×	LR:(300/300, 3, 1, 32, 32) HR:(300/300, 3, 1, 128, 128)	时间维度为 3 帧，空间上采样为 4 倍。输入粗糙，用于模拟包含时间信息的数据，对模型时空建模能力要求高。
TCW2	2×	LR:(1024/300, 1, 1, 64, 64) HR:(1024/300, 1, 1, 128, 128)	无时序结构，空间上采样为 2 倍。用于模拟低空间分辨率的实际观测数据。
TCW4	4×	LR:(1024/300, 1, 1, 32, 32) HR:(1024/300, 1, 1, 128, 128)	无时序结构，空间上采样为 4 倍。输入更粗糙，对模型空间建模能力要求更高。
TCW8	8×	LR:(1024/300, 1, 1, 16, 16) HR:(1024/300, 1, 1, 128, 128)	本次实践最大尺度的数据。用于检验模型在比较低分辨率下的性能与添加物理一致性约束后表现。

2.3 部分数据集可视化




图 2 TCW 系列验证集 target 数据前 10 张

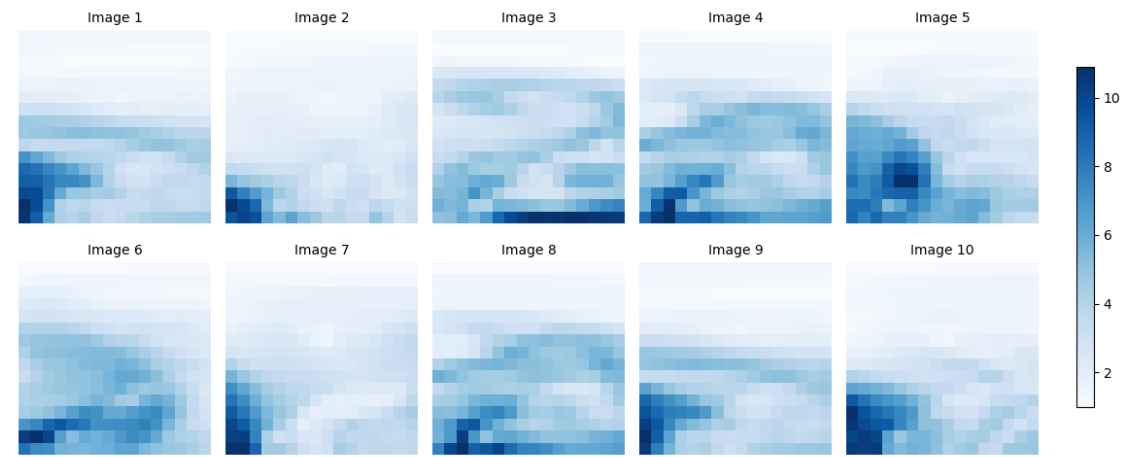


图 3 TCW8 训练集 input 数据前 10 张




图 4 T1 训练数据前 3 个样本 (LR)

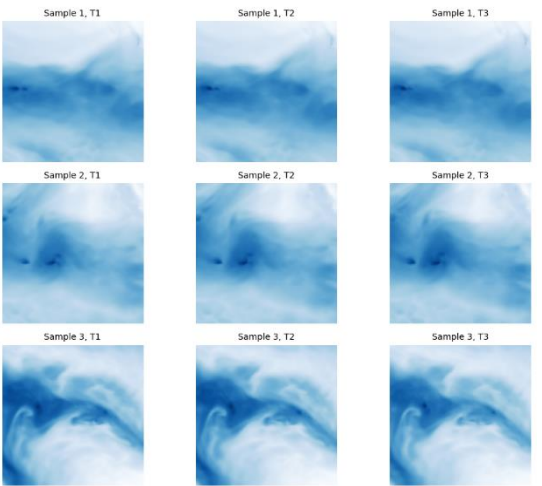


图 5 T1 训练数据前 3 个样本 (HR)

3 模型选择

为了全面探究气象降尺度任务中不同网络结构的表现以及物理一致性约束的适应性，本次实践分别引入了三类具有代表性的深度学习模型：卷积神经网络（CNN）、生成对抗网络（GAN）以及卷积门控循环单元（ConvGRU）。三类模型在建模空间细节、时序变化与感知真实性方面各具优势。

3.1 卷积神经网络 CNN

在降尺度任务中，最核心的目标是构建低分辨率（LR）图像与其对应的高分辨率（HR）图像之间的映射关系。卷积神经网络（CNN）因其局部感知机制和权值共享特性，在图像处理中具有极强的特征提取与空间重构能力，非常适合用于学习 TCW 数据集中湿度影像的局部结构与空间模式。在本实践中，CNN 被作为基线模型，通过多层卷积操作对 LR 图像进行逐层增强，从而逐步恢复其 HR 图像所蕴含的空间细节。由于 TCW 数据中 LR-HR 配对关系明确、同一图像尺度下结构信息具有较强的可预测性，CNN 可以通过端到端的方式学习并泛化这种映射规律。因此，它不仅具备良好的重建能力，也为后续引入物理约束机制提供了清晰的对照基础。

3.2 生成对抗网络 GAN

虽然 CNN 能够实现较为准确的空间映射，但在实际的遥感降尺度任务中，高分辨率湿度图像往往包含复杂的边缘结构与纹理细节，仅靠传统重建损失（如 MSE）难以刻画图像的主观真实感。为此，本实践引入生成对抗网络（GAN），通过判别器引导生成器在还原图像时更加关注高频细节和感知层面的一致性。GAN 的引入显著可能提升降尺度图像在视觉层面上的质量，使其更接近真实湿度图像的物理分布与结构状态。在使用 GAN 的过程中，模型虽能有效增强图像的局部表现力，但也存在生成结果可能违背物理约束的风险，因此在后续实验中，我们通过引入约束机制对其进行物理一致性的校正，从而实现感知质量与物理合理性的双重平衡。

3.3 卷积门控循环单元 ConvGRU

在本次实践的数据集 T1 中，一部分样本不仅包含空间信息，还包含时间维度上的演化趋势。为了捕捉湿度图像序列在时间维度上的动态变化，我们引入了具备时序建模能力的卷积门控循环单元（ConvGRU）。相较于普通 RNN 或 GRU 结构，ConvGRU 在状态更新中保留了空间结构信息，使其在时空建模任务中表现更加稳定且具有物理解释性。在降尺度背景下，ConvGRU 能够融合历史帧的动态信息，建模湿度场在多个时间步的变化趋势，从而提升对当前帧 HR 图像的预测准确性。特别是在面向实际天气过程的建模中，ConvGRU 不仅提高了预测连续性，也增强了输出结果在物理量演化规律上的可信度，是实现时序一致性与物理守恒性的重要构件。

4 建模与实现

4.1 Softmax 约束层的设计




图 6 Softmax Constraining Layer (SmCL) 的工作原理

Softmax 约束层被统一添加于各个网络结构的输出阶段，对每一个低分辨率输入像素 x ，网络首先预测出对应的高分辨率超像素块（如 2×2 ），然后通过约束机制对初始预测值进行规范化处理，使得最终输出超像素之和严格等于输入像素值，即满足 $\sum_{i=1}^n y_i = x$ 。其物理意义是所有像素点水汽质量总和一致同时保证每个像素点的预测值均为正数（水汽质量不可能为负值）。

4.2 CNN 的实现

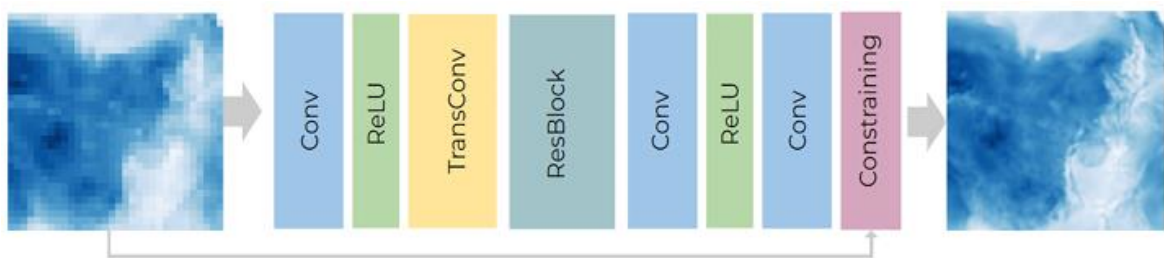


图 7 CNN 模型结构示意图

本实践中，CNN 作为基线模型，通过堆叠多个卷积层与非线性激活函数来学习从低分辨率（LR）到高分辨率（HR）图像的非线性映射关系。模型首先利用一层卷积提取基础特征，随后引入多个残差块以增强网络深度并提高表示能力，缓解梯度消失问题。上采样操作由转置卷积（`stride=2`）实现，使特征图尺寸逐步恢复至目标分辨率。网络最后一层使用卷积将多通道特征整合为单通道输出，生成最终的高分辨率图像。该结构具有收敛速度快、训练稳定等优点，适合作为降尺度任务的基准模型。模型架构图如图 7 所示，相关参数设置在附录展示。

4.3 GAN 的实现

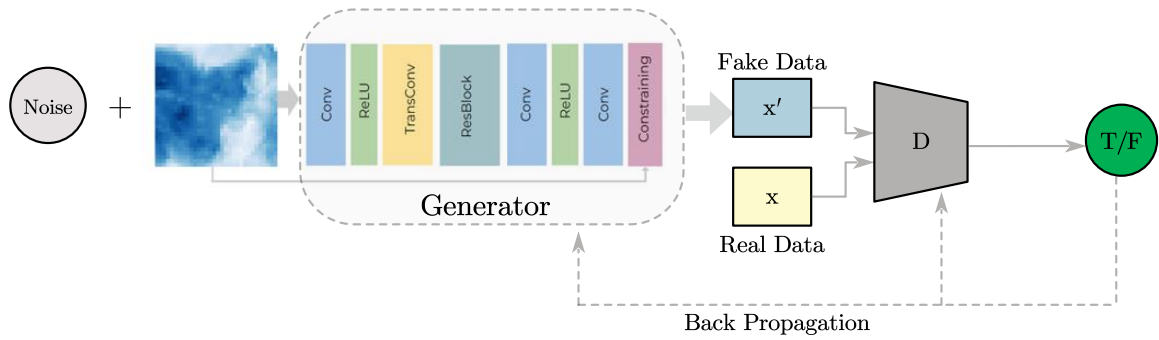


图 8 GAN 模型结构示意图

生成对抗网络（GAN）的生成器结构延续了 CNN 的主体框架，判别器采用典型的 PatchGAN 架构，通过局部判别增强高频细节学习。GAN 的损失函数为感知损失（MSE）与对抗损失的加权组合，其中感知损失引导结构还原，对抗损失提升纹理真实性。模型架构如图 8 所示，相关参数如附录所示。

4.4 ConvGRU 的实现

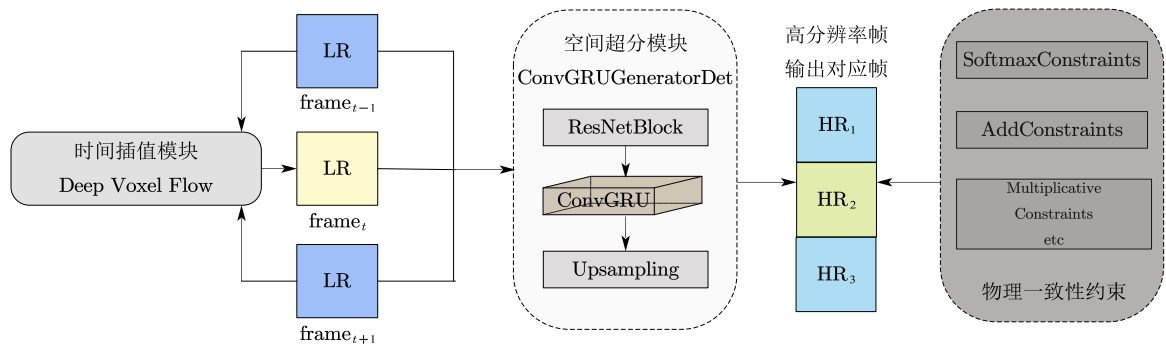


图 9 SR-FlowconvGRU 模型结构示意图

针对包含时间信息的数据集，为建模湿度数据的时序演化规律，引入了 ConvGRU 模型结构。该模型可同时保留时间动态信息与空间特征，具备建模气象演化趋势的能力。模型前置 CNN 提取初步特征，后接 ConvGRU 结构处理时序动态，最后通过卷积解码输出高分辨率图像。损失函数同样选用 MSE，强调数值预测的准确性。模型架构如图 9 所示，相关参数设置如附录所示。

5 训练测试

5.1 实验设计

为了全面评估物理一致性约束的影响，实验设计上我逐步控制变量，从是否引入时序建模、是否加入物理约束的出发，构建了以下对比实验，系统分析物理因素对模型性能的影响。考虑到时间和算力有限，本次实践所有模型均训练 20 轮次。

表 5 对比实验设计

编号	数据集	上采样倍数	模型	物理约束	实验目的简述
E1	TCW2	2×	CNN	None	基线模型：简单 CNN 无约束
E2	TCW2	2×	CNN	Softmax	Softmax 物理约束对 CNN 的效果
E3	TCW4	4×	CNN	None	基线模型：简单 CNN 无约束
E4	TCW4	4×	CNN	Softmax	Softmax 物理约束对 CNN 的效果
E5	TCW4	4×	ConvGRU	None	基线 ConvGRU 建模性能
E6	TCW4	4×	ConvGRU	Softmax	加入 Softmax 约束对 ConvGRU 的提升
E7	TCW4	4×	ConvGRU	Soft	Soft 软约束的协同效果
E8	TCW4	4×	GAN	None	GAN 在无约束条件下性能
E9	TCW4	4×	GAN	Soft	GAN 结合 Soft 软约束
E10	TCW4	4×	GAN	Softmax	GAN 结合 Softmax 物理一致性约束
E11	TCW8	8×	GAN	None	高倍放大下，GAN 性能表现
E12	TCW8	8×	GAN	Softmax	高倍放大下，加入 Softmax 物理约束效果

为了探究物理约束对时间和空间在降尺度任务的影响，与不包含约束的模型进行对比，粗略衡量加入物理约束后对降尺度水平的影响。故完成以上对比实验后，在 T1 数据集的训练集上分别训练 SR-FlowConvGRU（none 和 softmax 均 20 轮次），并在验证集上评估模型效果，对比分析得出加入物理约束层对包含时序信息的降尺度模型效果的影响。

5.2 训练评估流程

表 6 指标解读

指标名称	解读说明
MSE	衡量预测值与真实值之间的平均平方差，MSE 接近 0 表示模型预测非常精确。
PSNR	用于衡量图像质量，通常超过 35dB 被认为是高质量恢复。
MAE	预测值与真实值之差的绝对值平均值，表示整体偏离程度。
SSIM	衡量图像在亮度、对比度、结构上的相似度，值越接近 1 表示结构还原越逼真。
neg num	与负值像素均值配合，用于量化异常像素出现的频率，理想结果应为 0。
CRPS	衡量预测概率分布与实际结果之间的差距，<0.4 通常视为优秀水平。

首先加载训练数据（data 目录中的.pt 文件），分别提取输入 LR 帧和目标 HR 帧。其次对于我用的模型而言，在训练脚本中调用不同的模块（CNN、GAN、

ConvGRU/FlowConvGRU) 计算网络输出, 并通过 MSE 损失与真实 HR 对比同时统计守恒违规。Softmax 约束层直接调整输出确保守恒, 因此可以视为硬性约束而非损失项。训练配置如学习率、批大小等参见前面的模型参数表。训练完成后, 评估时读取验证集 LR 数据, 得到对应预测出的 HR, 并输出对比图和评价指标 (PSNR、SSIM 等), 各个指标的解读如表 6 所示。

6 结果与分析

表 6 TCW 上对比实验结果统计

编号	模型	MSE	RMSE	PSNR	MAE	SSIM	neg num	CRPS
E1	CNN_TCW2_none	0.0678	0.2604	51.7782	0.1385	0.9966	37	0.0000
E2	CNN_TCW2_softmax	0.1639	0.4049	47.9449	0.2283	0.9928	59	0.0000
E3	CNN_TCW4_none	0.9589	0.9792	40.2736	0.5489	0.9712	0	0.0000
E4	CNN_TCW4_softmax	0.1817	0.4262	47.4989	0.2099	0.9909	0	0.0000
E5	ConvGRU_TCW4_none	0.9637	0.9817	40.2519	0.5255	0.9745	64	0.0000
E6	ConvGRU_TCW4_softmax	0.2041	0.4518	46.9928	0.2208	0.9897	0	0.0000
E7	ConvGRU_TCW4_soft	1.1219	1.0592	39.5919	0.5942	0.9724	23	0.0000
E8	GAN_TCW4_none	1.4214	1.1922	38.5644	0.7045	0.9426	1	0.3589
E9	GAN_TCW4_soft	0.9375	0.9683	40.3716	0.5857	0.9634	0	0.3564
E10	GAN_TCW4_softmax	0.2002	0.4474	47.0773	0.2284	0.9896	0	0.1149
E11	GAN_TCW8_none	2.9574	1.7197	35.3824	1.0756	0.9207	6071	0.4570
E12	GAN_TCW8_softmax	1.5100	1.2288	38.3016	0.7110	0.9434	0	0.3577

表 7 T1 实验结果统计

模型	MSE	RMSE	PSNR	MAE	SSIM	neg num	CRPS
FlowConvGRU_T1_none	476.15	21.2821	13.201	16.761	0.181	1057907	0.0000
FlowConvGRU_T1_softmax	0.6842	0.8272	41.6272	0.3643	0.9783	0	0.0000

6.1 约束对 CNN 的影响分析

(1) E1 vs E2 (TCW2)

添加 Softmax 约束后, MSE 从 0.0678 上升至 0.1639, PSNR 降低约 3.83dB, MAE 与 RMSE 均显著变大, 且负值像素数从 37 增至 59, 显然并没有成功应用约束。这表明在低倍数上采样任务中, Softmax 强制守恒约束反而会造成模型训练偏离数据分布, 带来性能退化。

(2) E3 vs E4 (TCW4)

与上组不同, 在 TCW4 上 Softmax 明显改善性能: MSE 从 0.9589 降至 0.1817, PSNR

提高 7.22 dB，SSIM 从 0.9712 提升至 0.9909，且完全消除了负值像素，满足了物理一致性约束。这说明物理约束在高放大任务中具有更强的正面作用，能够同时显著提升重建图像的质量与物理合理性。

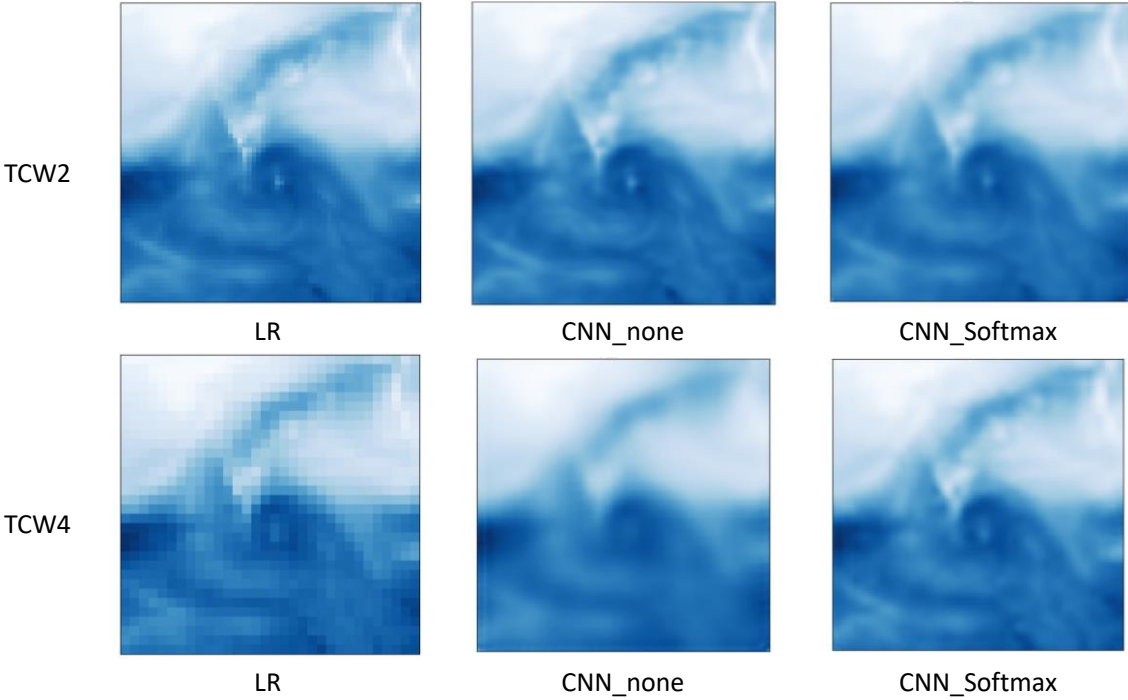


图 10 CNN 相关的实验结果（选取数据集中特定帧展示）

6.2 约束对 ConvGRU 的影响分析

（1）E5 vs E6（TCW4）

类似于 CNN 的趋势，Softmax 在 ConvGRU 模型中同样带来了大幅性能提升。MSE 从 0.9637 降至 0.2041，PSNR 提高 6.74 dB，SSIM 从 0.9745 提高至 0.9897，体现了时间建模与物理约束之间存在协同增益效应。

（2）E6 vs E7（TCW4）

相比硬性 Softmax，Soft 软约束的性能退化明显：MSE 达到 1.1219，PSNR 降至 39.59 dB，MAE 和负值像素数也更大，说明软约束无法像 Softmax 一样明确保证物理一致性，反而可能造成模型训练不稳定。




图 11 ConvGRU 相关的实验结果（选取数据集中特定帧展示）

6.3 约束对 GAN 的影响分析

(1) E8 vs E9 (TCW4)

添加 Soft 软约束后，GAN 模型的性能明显提升：MSE 从 1.4214 降至 0.9375，PSNR 提高至 40.37 dB，SSIM 升至 0.9634，同时 CRPS 从 0.3589 降至 0.3564。虽然提升幅度不如 Softmax 显著，但依然表明软约束对 GAN 模型的训练具有正向引导作用，有助于提升重构质量的同时抑制无物理意义的预测值。

(2) E8 vs E10 (TCW4)

相比之下，Softmax 物理约束带来最显著的性能提升：MSE 降至 0.2002，PSNR 高达 47.08 dB，SSIM 达到 0.9896，且 CRPS 显著降低至 0.1149，为所有 GAN 实验中的最优结果。该结果强烈支持了 Softmax 在 GAN 结构中的有效性，说明强约束能显著强化生成模型的守恒能力和数据一致性。

(3) E11 vs E12 (TCW8)

Softmax 约束在极端低分辨率任务中同样有效：MSE 减少 1.44，PSNR 提高近 3 dB，SSIM 提升至 0.9434，同时负值像素数从 6071 下降至 0，CRPS 也下降到 0.3577。这说明约束机制在复杂任务下具有更为显著的稳健性与泛化性。

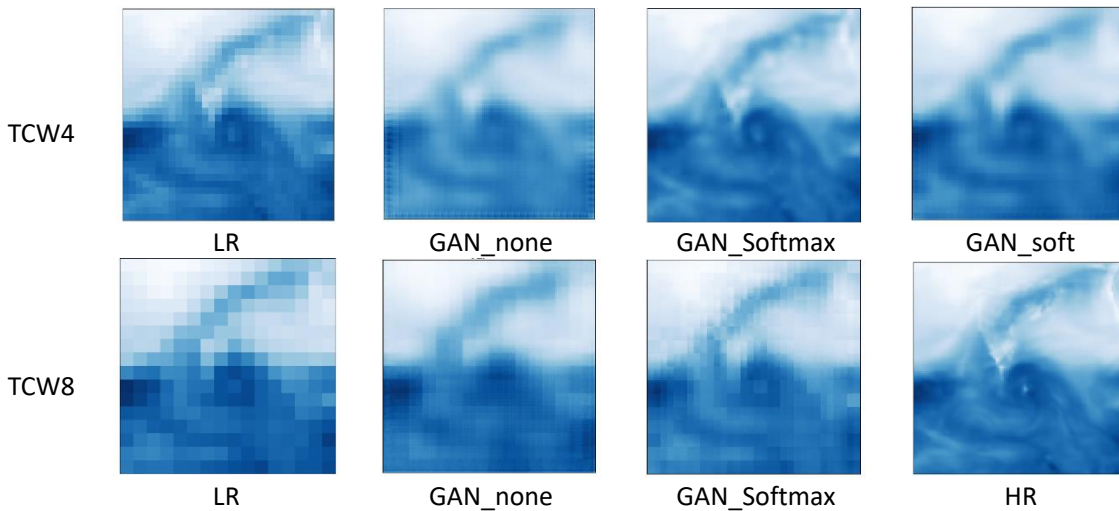


图 12 GAN 相关的实验结果（选取数据集中特定帧展示）

6.4 约束对 FlowConvGRU 的影响分析

引入 Softmax 约束后，模型性能得到了显著提升。FlowConvGRU_T1_softmax 模型在均方误差和平均绝对误差上分别降至 0.6842 和 0.3643，远低于未加约束的 FlowConvGRU_T1_none 模型的 476.15 和 16.761，表明预测更加精确。此外，PSNR 从 13.201 提升至 41.627，说明图像重建质量大幅提高；SSIM 也从 0.181 上升至 0.978，反映出预测图像在结构和纹理方面更接近真实图像。最为关键的是，加入 Softmax 约束后，负值像素数为 0，而无约束模型中负值多达 1057907 个，体现了物理一致性约

束在提升预测合理性和物理可解释性方面的必要性。

该实验改善效果优于以上对比实验中的任意一个实验，可能预示着引入时序信息之后，模型对接近现实情境的要求更高了，没有约束的情况下不符合物理可解释性，在模型引入时序信息后导致预测成为灾难。引入 Softmax 约束前后，模型降尺度效果的可视化图像如图 9、10 所示。




图 13 不加约束的预测结果




图 14 加入 Softmax 约束的预测结果

图 10 加入 Softmax 约束的预测结果

7 结论

综合以上所有实验结果可以得出以下结论：引入物理一致性约束（本次实践主要探索的是 Softmax 强约束）能够在多数情境下显著提升模型性能，改善重建图像的物理合理性与数值精度，但具体效果仍依赖于模型结构与任务复杂度的匹配程度。在 CNN 模型中，Softmax 约束在低倍率（TCW2）下性能下降，但在高倍率任务（TCW4）中却极大提升了 PSNR、SSIM 等指标，初步说明此类约束更适用于较高分辨率的重建场景。在 ConvGRU 中，单帧超分建模与物理约束形成良好协同，Softmax 约束下模型各项指标均优于无约束版本；而 Soft 软约束则表现出不稳定性，强调了强约束在建模任务中的优势。对于 GAN 模型，Soft 与 Softmax 均有助于提升重构质量，其中 Softmax 约束在各项指标上全面领先，甚至在高放大倍数（TCW8）下仍能显著减少负值像素与 CRPS 误差，表现出极强的稳健性与泛化能力。当引入时序信息之后 FlowConvGRU 加入 Softmax 约束之后的性能快速飞升，有力地说明了物理一致性约束在提升预测合理性和物理可解释性方面的必要性。

气象遥感数据降尺度正朝着更高分辨率、更高物理可信度和更广应用范围的方向发展。未来的研究将更加注重将大数据技术与大气物理知识深度融合，利用先进的深度学习算法提升空间分辨率的同时，确保结果符合大气科学规律并具有业务实用价值，为应对气候变化和减灾防灾提供强有力的技术支撑。

8 附录

各个模型参数一览：

参数类别	CNN	GAN 生成器	GAN 判别器	ConvGRU
卷积核大小	3×3	3×3	3×3	3×3
卷积层数量	3 层	-	7 层	前置 2 层+后置 2 层
通道数	输入 1 \rightarrow 64 \rightarrow 输出 1	输入 1 \rightarrow 64 \rightarrow 输出 1	1 \rightarrow 32 \rightarrow 32 \rightarrow 64 \rightarrow 64 \rightarrow 128 \rightarrow 128 \rightarrow 1	GRU 隐藏 64
时间维度	无	无	无	输入帧数为 3 或 1
激活函数	ReLU	ReLU	ReLU (inplace=True)	ReLU
上采样方式	转置卷积 (stride=2)	转置卷积 (stride=2)	-	后置卷积+上采样
判别方式	-	-	PatchGAN	-
损失函数	MSE	MSE + λ 对抗损失	BCE (二元交叉熵)	MSE
对抗损失权重 λ	-	0.01	-	-
优化器	Adam	Adam	Adam	Adam
学习率	0.001	0.001	同生成器	0.001
Batch Size	64	64	同生成器	64
训练轮数	20	20	同生成器	20

由于代码量过大，不单独列出，请访问我的 [github](#) 了解详情。

[yurururu GitHub](#) (项目已托管到 github, 点击查看)