

# 南京信息工程大学

## 《气象遥感大数据分析》 期末课程总报告



标题     如何应用大数据技术赋能气象遥感研究和应用

名字     王玉茹

学号     202283250057

院部     未来技术学院

专业     数据科学与大数据技术

授课教师     汤雨恒

二〇二五 年 六 月 十八 日

# 1. 引言

气象遥感数据的空间降尺度（Spatial Downscaling）是指利用大尺度、低分辨率的气象数据推断局地高分辨率信息，以提高数据的空间细节表现。传统方法包括动力降尺度（利用中尺度数值模式嵌套模拟）和统计降尺度两大类。动力降尺度遵循物理模型，可以显式模拟从粗尺度到细尺度的大气动力过程，但计算量巨大且容易引入模式偏差。相比之下，统计降尺度通过建立历史大尺度与小尺度变量之间的统计映射，具有实现简便、计算成本低的优势。例如，经典的统计模型包括多元线性回归、基于分位数的回归和随机天气发生器等。其中，Wilby 等人提出的统计降尺度模型（SDSM）将多元线性回归与随机天气发生器相结合，实现大尺度气候变量到局地逐日气象的转换。SDSM 在构建关系前常对预测因子进行相关性筛选和非线性变换，并假设这种统计关系在气候变化情景下仍保持不变。此外，还有基于天气类型分组的方法，通过聚类或分类大尺度环流型，每类分别建立局地响应模型，从而兼顾天气情景的信息。然而，这些传统统计方法往往难以捕捉复杂的非线性关系，对长时间高质量观测数据依赖强，且隐含假设所建关系在非平稳气候下依旧适用，这在气候变化背景下存在不确定性。

近二十年来，随着机器学习的发展，一些非线性模型也被引入统计降尺度领域。例如，支持向量机（SVM）、随机森林（RF）和人工神经网络（ANN）等已经用于构建粗细尺度气象要素的映射。这些方法相较于简单的线性回归，能够一定程度捕捉非线性关系，在降尺度精度上有所提升。然而，传统机器学习模型在提取复杂特征关联方面仍有局限，需要人工选择预测因子，且难以充分利用海量气象大数据中的时空模式。随着深度学习（Deep Learning）的兴起，气象降尺度开始借鉴计算机视觉中的图像超分辨率（Super Resolution, SR）技术，通过深层神经网络自动学习低分辨率（LR）与高分辨率（HR）数据之间的映射。深度卷积神经网络（CNN）能够从海量数据中提取多层次特征，对于复杂的非线性映射具有强大的拟合能力。Vandal 等人率先提出 DeepSD 框架，将深度超分辨率 CNN 应用于气候数据降尺度，实现将全球气候模型输出下采样至局地高分辨率。此后，Shi 等人提出的 ESPCN 利用亚像素卷积直接学习上采样，高效地提高分辨率；Lim 等人的 EDSR 通过去除批归一化等技巧获得更高重建精度；Ledig 等人的 SRGAN 引入生成对抗网络，在提升图像细节真实感方面表现突出。这些模型被陆续应用于降水、气温、风场等降尺度研究中，并取得比传统方法更优的结果。Stengel 等人将 GAN 用于气候场超分辨率，实现了原始分辨率的 50 倍提升；Kurinchi-Vendhan 等人对比了 ESRGAN、EDSR 等先进 SR 模型在风能与太阳能数据降尺度中的效果，验证了深度学习方法相对于插值和回归方法的优势。

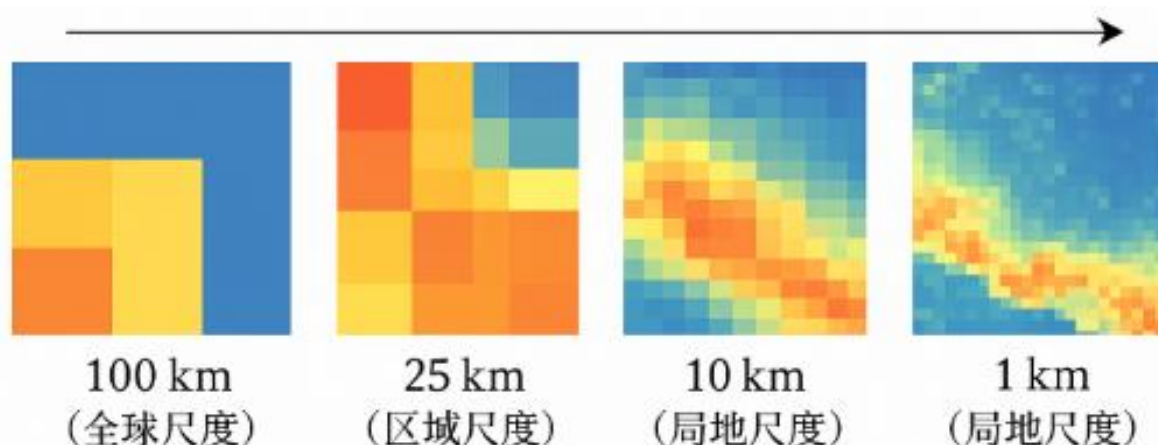


图 1 气象场降尺度示意图

虽然深度学习驱动的降尺度显示出强大性能，但也面临一些共性挑战。首先，模型对训练数据依赖很强，高低分辨率配对数据难以获取或不足时，模型性能会显著下降。许多卫星或者再分析数据缺乏精确对应的更高分辨率“真值”，这限制了监督学习范式的应用。其次，深度模型在训练数据分布之外的泛化能力较弱，如果将其应用于不同区域、季节或更极端的气候状况，往往效果不稳定。这使得降尺度结果在时空转移时可能失真或精度下降，这是当前研究中的难点之一。此外，深度网络以逐像元误差为优化目标，得到的高分影像有时在物理上一致性不足，可能违背基本守恒定律等约束。例如，对降水等变量进行超分辨率重建时，若不加以约束，模型可能在小尺度上凭空生成或丢失水量，导致总雨量不守恒等问题。这种物理不一致性不仅削弱结果的可信度，也限制了降尺度产品在后续数值预报或水文模拟中的应用。另外，深度学习模型大多属于“黑箱”，缺乏对因果物理机制的解释，加之模型参数量大，部署于业务和终端（边缘）环境也存在困难。综上所述，在追求更高空间分辨率的同时，如何保持结果稳定可靠、物理合理且具备跨区域的泛用性，成为气象遥感降尺度领域亟待解决的挑战。

为应对上述问题，近年来兴起了将物理机理约束融合到深度降尺度中的研究思路。一方面，在网络架构上引入物理先验信息。例如物理信息神经网络（PINNs）通过在损失函数中加入偏微分方程残差，使模型在训练中满足特定物理方程；又如 Wang 等人提出将流体方程约束融入超分辨率网络，对平流扩散过程进行下尺度重建。另一方面，结合对抗训练与物理判别器，设计 Physics-Informed GAN 或加入硬约束层。例如 Junzhe Yin 等在极端降雨临近预报中构建 PID-GAN，将向量量化 VQ-GAN 与 Transformer 相结合，并在判别器中嵌入物理引导项，以确保模型输出符合降水的物理分布特征。Harder 等人则提出在深度降尺度网络末端增加强制约束层，通过重新归一化输出场使其严格满足大尺度守恒等物理条件。还有一些研究在网络结构中融合多尺度动力信息，如 ERU-Net（增强残差 U-Net）模型在进行 ERA5 再分析数据的时间降尺度时，引入了流场辅助信息和涡度平流损失（advection loss），在捕捉多尺度演变的同时保证了基本动力学规律的一致。这些融合物理机制的降尺度方法在一定程度上提升了结果的可信度，被认为是下一代气象降尺度的重要发展方向。

表 1 气象降尺度代表性方法

方法类别	代表模型/方法	优点	缺点
传统统计降尺度	多元线性回归 SDSM 天气型分组等	理论简单 实现和迁移方便 计算开销低 可用于生成未来情景数据	难以捕捉非线性关系，需长序列观测校准，对极值和新型气候情况适应性差
传统机器学习	SVM 随机森林 ANN 等	能拟合一定非线性关系 比线性方法精度提升	依赖人工特征选择，难以提取深层次时空模式；非线性能力有限
深度学习 SR	SRCNN ESPCN EDSR 等	自动学习多层次特征 能逼近复杂非线性映射 在典型数据上显著提高降尺度的精度	对高质量配对数据需求量大；结果可能缺乏物理一致性；模型参数多、训练和调参较复杂
对抗生成 SR	SRGAN	能生成更锐利、逼真的细节纹理	训练过程不稳定，需精心平衡生成

方法类别	代表模型/方法	优点	缺点
	ESRGAN 等	在视觉效果上优于纯 CNN 可通过判别器指导改善小尺度结构重建	器与判别器；对物理意义的保障不足
物理约束 深度方法	PINN 物理网络 Physics-GAN ERU-Net 等	融合物理规律提高模型可靠性， 输出满足守恒等约束，提升外推 泛化能力；可结合多源数据和多 任务，提高对复杂气候情景的适 应性	模型结构更复杂，训练难度和成本 增加；物理约束选择和权重需专业 知识，不当约束可能降低数值精 度；目前多为特定场景定制，通用 性有待验证

综上所述，当前气象遥感的降尺度技术正逐步由传统的统计建模方法向深度学习驱动的方式演进，并进一步发展出融合物理一致性约束的新路径。基于以上，本文实践环节聚焦于一种结合神经网络（NN）与物理守恒约束机制的深度学习降尺度方案，借鉴了 *Physics-Constrained Deep Learning for Climate Downscaling* 等代表性工作。在数据驱动的监督学习框架下，模型以低分辨率（LR）与高分分辨率（HR）遥感气象数据构建训练对，进行 2 倍至 8 倍的空间分辨率重建。

## 2. 实践部分

### 2.1 方法原理

#### 2.1.1 物理一致性约束层的工作原理




图 2 Softmax Constraining Layer (SmCL) 的工作原理

在本次实践中，引入了物理一致性约束机制：加法约束、乘法约束和 Softmax 约束等以确保超分辨率模型的输出在物理意义上具备守恒性。这些约束层被统一添加于网络结构的输出阶段，对每一个低分辨率输入像素  $x$ ，网络首先预测出对应的高分辨率超像素块（如  $2 \times 2$ ），然后通过约束机制对初始预测值进行规范化处理，比如此处使得最终输出超像素之和严格等于输入像素值，即满足  $\sum_{i=1}^n y_i = x$ 。具体而言，加法约束通过对预测值进行平移修正以补偿偏差，乘法约束则通过比例缩放实现守恒，而 Softmax 约束利用可微分的 Softmax 归一化方式获得更稳定的修正效果。具体的约束类型及解读如表 2 所示。

表 2 物理一致性约束

约束类型	说明	特点
Softmax	输出经 Softmax 归一化后乘以输入	非负且总和守恒，最常用
Add	向输出加上偏移量以保持守恒	简单稳定，适应性强
Mult	输出整体乘以缩放因子	效果好，但对接近 0 的输入不稳定
Soft	将守恒误差作为损失项引入	软约束，可调节权重
None	无任何守恒限制	用作对照基线

### 2.1.2 模型架构

本次实践探索三种模型对物理一致性约束层的适用程度，包括 CNN、GAN、ConvGRU 三种模型。



图 3 SR-CNN 模型结构示意图

本次实践采用的 SR-CNN 由多个使用  $3 \times 3$  卷积核和 ReLU 激活函数的卷积层构成。上采样操作由反卷积完成，后接残差块。采用上述 CNN 架构作为生成器网络，判别器以真实 HR 图像和生成图像为输入，使用二元交叉熵损失进行训练，以区分真假图像。生成器以高斯噪声和 LR 图像为输入，输出预测的 SR 图像。训练目标是最小化 MSE 损失和来自判别器的对抗损失，两者联合优化。




图 4 SR-GAN 模型结构示意图

此外本次实践还引入了光流插值模块对时序信息进行建模，探索时间建模+物理约束的协同增益效果。它主要包含以下几个模块：

- (1) 时间插值模块（Deep Voxel Flow）：采用 Liu 等（2017）提出的帧插值网络，对两个时刻的低分辨率数据进行深度光流插值，生成中间时刻的估计帧。这一步将时间分辨率提高至原来的三倍，使得后续空间超分可同时处理多时刻数据。
- (2) 空间超分模块（ConvGRUGeneratorDet）：该模块基于 ResNet 构建上采样网络，包括多层残差块用于提取和重建空间特征，并使用卷积 GRU 层融合时间步信息。具体地，ConvGRUGeneratorDet 接受

三个时间步的 LR 输入，通过一系列卷积、残差连接和上采样层逐步恢复高分辨率图像。在代码中，用 `number_channels`、`number_residual_blocks`、`upsampling_factor` 等参数控制网络宽度、深度和上采样倍数。使用 ResNet 结构可以加深网络深度而缓解梯度衰减，同时残差连接方便学习细节补偿；ConvGRU 层则利用隐状态将前后帧的信息结合，提高时序连贯性。整个空间超分网络和时间插值网络可端到端联合训练。这个模块也可以接收单个时间帧，只做空间超分。

(3) 物理一致性约束层：在网络最后一层，对生成的 HR 预测图像施加物理约束。

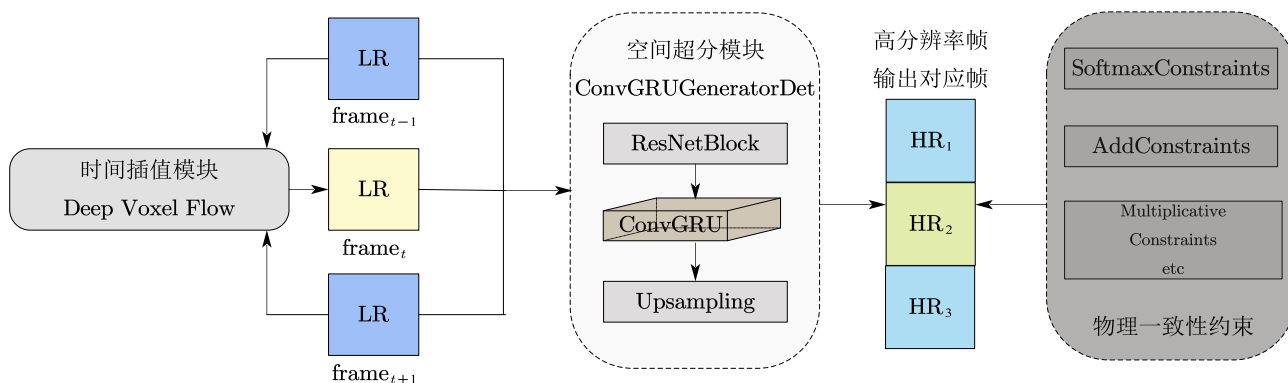


图 5 SR-FlowconvGRU 模型结构示意图

## 2.2 实操过程

### 2.2.1 数据集准备与预处理

本次实践使用的数据集包含总柱水量（total column water, TCW）中配对的低分辨率（LR）和高分辨率（HR）影像。高分辨率影像空间分辨率为原始数据的 2–8 倍，低分辨率影像则通过对高分辨率数据进行下采样模拟得到（采用双三次卷积降采样方法）。在制作 LR-HR 样本对时，确保了二者在时间和空间上的严格对齐，即每个 LR 网格对应嵌套的 HR 网格区域。为了加速收敛，我对输入数据进行了归一化预处理，将各变量值缩放到[0,1]。对于模型训练，低分辨率影像被零填充或双线性插值至与高分辨率相同尺寸，以便与模型输出直接计算损失，数据集经预处理后以 PyTorch 原生的 .pt 二进制格式序列化保存，用于高效加载与张量结构的直接复现。

表 3 数据集说明

名称	上采样倍数	数据集维度 (train/val)	特征说明
T1	4×	LR:(300/300, 3, 1, 32, 32) HR:(300/300, 3, 1, 128, 128)	时间维度为 3 帧，空间上采样为 4 倍。输入粗糙，用于模拟包含时间信息的数据，对模型时空建模能力要求高。
TCW2	2×	LR:(1024/300, 1, 1, 64, 64) HR:(1024/300, 1, 1, 128, 128)	无时序结构，空间上采样为 2 倍。用于模拟低空间分辨率的实际观测数据。
TCW4	4×	LR:(1024/300, 1, 1, 32, 32) HR:(1024/300, 1, 1, 128, 128)	无时序结构，空间上采样为 4 倍。输入更粗糙，对模型空间建模能力要求更高。
TCW8	8×	LR:(1024/300, 1, 1, 16, 16) HR:(1024/300, 1, 1, 128, 128)	本次实践最大尺度的数据。用于检验模型在比较低分辨率下的性能与添加物理一致性约束后表现。



2.2.2 具体实验设计

为了全面评估物理一致性约束的影响，本次实践涵盖了以上多个不同尺度的数据集。实验设计上我逐步控制变量，从是否引入时序建模、是否加入物理约束和加入的约束层的类型等角度出发，构建了以下对比实验，系统分析物理因素对模型性能的影响。考虑到时间和算力有限，本次实践主要研究 Softmax 约束的影响（每个实验 20 轮次），其他约束层的研究方式类似。

表 4 对比实验设计

编号	数据集	上采样倍数	模型	是否处理时序	物理约束	实验目的简述
E1	TCW2	2×	CNN	否	None	基线模型：简单 CNN 无约束
E2	TCW2	2×	CNN	否	Softmax	Softmax 物理约束对 CNN 的效果
E3	TCW4	4×	CNN	否	None	基线模型：简单 CNN 无约束
E4	TCW4	4×	CNN	否	Softmax	Softmax 物理约束对 CNN 的效果
E5	TCW4	4×	ConvGRU	否	None	基线 ConvGRU 建模性能
E6	TCW4	4×	ConvGRU	否	Softmax	加入 Softmax 约束对 ConvGRU 的提升
E7	TCW4	4×	ConvGRU	否	Soft	Soft 软约束的协同效果
E8	TCW4	4×	GAN	否	None	GAN 在无约束条件下性能
E9	TCW4	4×	GAN	否	Soft	GAN 结合 Soft 软约束
E10	TCW4	4×	GAN	否	Softmax	GAN 结合 Softmax 物理一致性约束
E11	TCW8	8×	GAN	否	None	高倍放大下，GAN 性能表现
E12	TCW8	8×	GAN	否	Softmax	高倍放大下，加入 Softmax 物理约束效果

为了探究物理约束对时间和空间在降尺度任务的影响，与不包含约束的模型进行对比，粗略衡量加入物理约束后对降尺度水平的影响。故完成以上对比实验后，在 T1 数据集的训练集上分别训练 SR-FlowConvGRU（none 和 softmax 均 20 轮次），并在验证集上评估模型效果，对比分析得出加入物理约束层对包含时序信息的降尺度模型效果的影响。

2.2.3 训练评估流程

表 5 指标解读

指标名称	解读说明
MSE	衡量预测值与真实值之间的平均平方差，MSE 接近 0 表示模型预测非常精确。
PSNR	用于衡量图像质量，通常超过 35dB 被认为是高质量恢复。
MAE	预测值与真实值之差的绝对值平均值，表示整体偏离程度。值越小，说明模型越准确。
SSIM	衡量图像在亮度、对比度、结构上的相似度，值越接近 1 表示结构还原越逼真。
neg num	与负值像素均值配合，用于量化异常像素出现的频率，理想结果应为 0。
CRPS	衡量预测概率分布与实际结果之间的差距，<0.4 通常视为优秀水平。

首先加载训练数据（data 目录中的.pt 文件），分别提取输入 LR 帧和目标 HR 帧。其次对于我用的模型而言，在训练脚本中调用不同的模块（CNN、GAN、ConvGRU/FlowConvGRU）计算网络输出，并通过 MSE 损失与真实 HR 对比同时统计守恒违规。Softmax 约束层直接调整输出确保守恒，因此可以视为硬性约束而非损失项。训练配置如学习率、批大小等参见代码说明（文档最后我的 github 网址）；训练完成后，评估时读取验证集 LR 数据，得到对应预测出的 HR，并输出对比图和评价指标（PSNR、SSIM 等）。

### 2.3 实验结果

为全面理解物理一致性约束对超分模型的作用，本节从不同模型架构出发，采用逐组对比的方式，分析约束前后的性能变化，重点指标包括 MSE、PSNR、SSIM、CRPS 及负值像素数等。

表 6 TCW 上对比实验结果统计

编号	模型	MSE	RMSE	PSNR	MAE	SSIM	neg num	CRPS
E1	CNN_TCW2_none	0.0678	0.2604	<b>51.7782</b>	0.1385	0.9966	37	0.0000
E2	CNN_TCW2_softmax	0.1639	0.4049	47.9449	0.2283	0.9928	59	0.0000
E3	CNN_TCW4_none	0.9589	0.9792	40.2736	0.5489	0.9712	<b>0</b>	0.0000
E4	CNN_TCW4_softmax	0.1817	0.4262	<b>47.4989</b>	0.2099	<b>0.9909</b>	<b>0</b>	0.0000
E5	ConvGRU_TCW4_none	0.9637	0.9817	40.2519	0.5255	0.9745	64	0.0000
E6	ConvGRU_TCW4_softmax	0.2041	0.4518	46.9928	0.2208	0.9897	<b>0</b>	0.0000
E7	ConvGRU_TCW4_soft	1.1219	1.0592	39.5919	0.5942	0.9724	23	0.0000
E8	GAN_TCW4_none	1.4214	1.1922	38.5644	0.7045	0.9426	1	0.3589
E9	GAN_TCW4_soft	0.9375	0.9683	40.3716	0.5857	0.9634	<b>0</b>	0.3564
E10	GAN_TCW4_softmax	0.2002	0.4474	<b>47.0773</b>	0.2284	<b>0.9896</b>	<b>0</b>	0.1149
E11	GAN_TCW8_none	2.9574	1.7197	35.3824	1.0756	0.9207	6071	0.4570
E12	GAN_TCW8_softmax	1.5100	1.2288	38.3016	0.7110	0.9434	<b>0</b>	0.3577

表 7 T1 实验结果统计

模型	MSE	RMSE	PSNR	MAE	SSIM	neg num	CRPS
FlowConvGRU_T1_none	476.15	21.2821	13.201	16.761	0.181	1057907	0.0000
FlowConvGRU_T1_softmax	0.6842	0.8272	41.6272	0.3643	0.9783	0	0.0000

#### 2.3.1 约束对 CNN 的影响分析

##### （1）E1 vs E2（TCW2）

添加 Softmax 约束后，MSE 从 0.0678 上升至 0.1639，PSNR 降低约 3.83dB，MAE 与 RMSE 均显著变大，且负值像素数从 37 增至 59，显然并没有成功应用约束。这表明在低倍数上采样任务中，Softmax 强制守恒约束反而会造成模型训练偏离数据分布，带来性能退化。

##### （2）E3 vs E4（TCW4）

与上组不同，在 TCW4 上 Softmax 明显改善性能：MSE 从 0.9589 降至 0.1817，PSNR 提高 7.22 dB，SSIM 从 0.9712 提升至 0.9909，且完全消除了负值像素。这说明物理约束在高放大任务中具有更强的正面作用，能



够显著提升重建图像的质量与物理合理性。

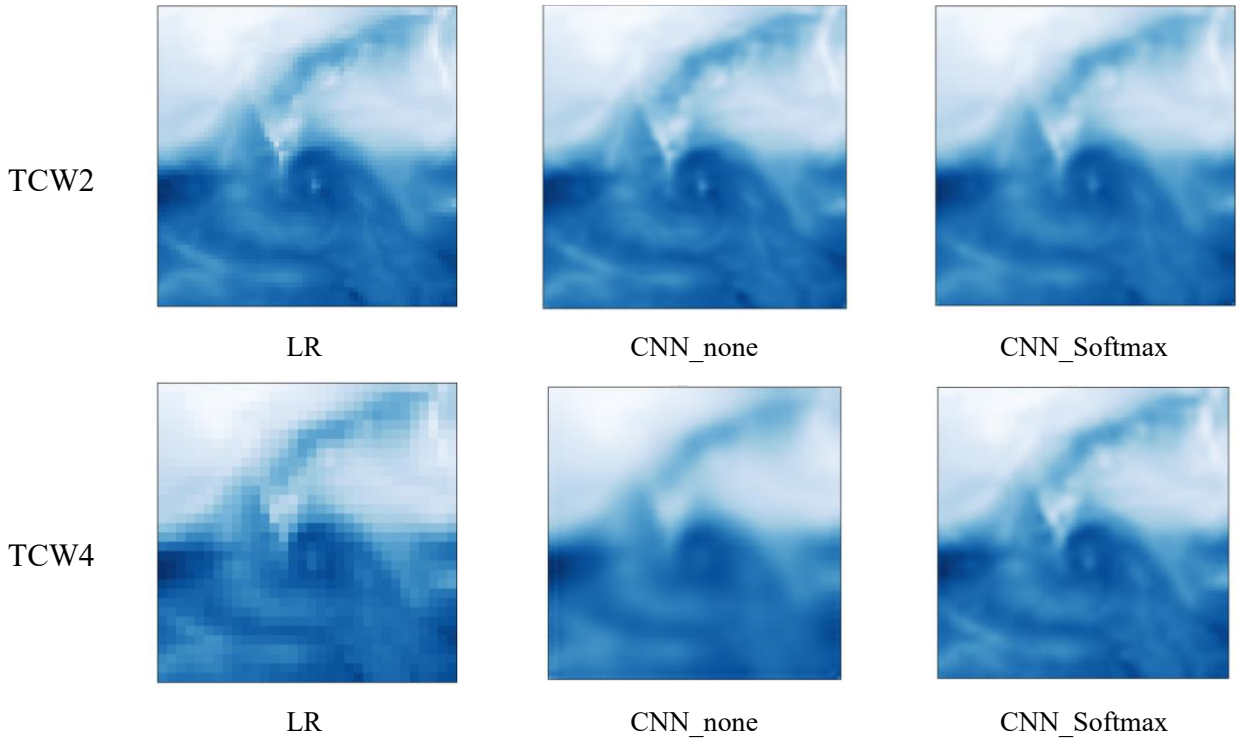


图 6 CNN 相关的实验结果（选取数据集中特定帧展示）

### 2.3.2 约束对 ConvGRU 的影响分析

#### （1）E5 vs E6（TCW4）

类似于 CNN 的趋势，Softmax 在 ConvGRU 模型中同样带来了大幅性能提升。MSE 从 0.9637 降至 0.2041，PSNR 提高 6.74 dB，SSIM 从 0.9745 提高至 0.9897，体现了时间建模与物理约束之间存在协同增益效应。

#### （2）E6 vs E7（TCW4）

相比硬性 Softmax，Soft 软约束的性能退化明显：MSE 达到 1.1219，PSNR 降至 39.59 dB，MAE 和负值像素数也更大，说明软约束无法像 Softmax 一样明确保证物理一致性，反而可能造成模型训练不稳定。




图 7 ConvGRU 相关的实验结果（选取数据集中特定帧展示）

### 2.3.3 约束对 GAN 的影响分析

#### （1）E8 vs E9（TCW4）

添加 Soft 软约束后，GAN 模型的性能明显提升：MSE 从 1.4214 降至 0.9375，PSNR 提高至 40.37 dB，SSIM 升至 0.9634，同时 CRPS 从 0.3589 降至 0.3564。虽然提升幅度不如 Softmax 显著，但依然表明软约束对 GAN 模型的训练具有正向引导作用，有助于提升重构质量的同时抑制无物理意义的预测值。

### (2) E8 vs E10 (TCW4)

相比之下，Softmax 物理约束带来最显著的性能提升：MSE 降至 0.2002，PSNR 高达 47.08 dB，SSIM 达到 0.9896，且 CRPS 显著降低至 0.1149，为所有 GAN 实验中的最优结果。该结果强烈支持了 Softmax 在 GAN 结构中的有效性，说明强约束能显著强化生成模型的守恒能力和数据一致性。

### (3) E11 vs E12 (TCW8)

Softmax 约束在极端低分辨率任务中同样有效：MSE 减少 1.44，PSNR 提高近 3 dB，SSIM 提升至 0.9434，同时负值像素数从 6071 下降至 0，CRPS 也下降到 0.3577。这说明约束机制在复杂任务下具有更为显著的稳健性与泛化性。

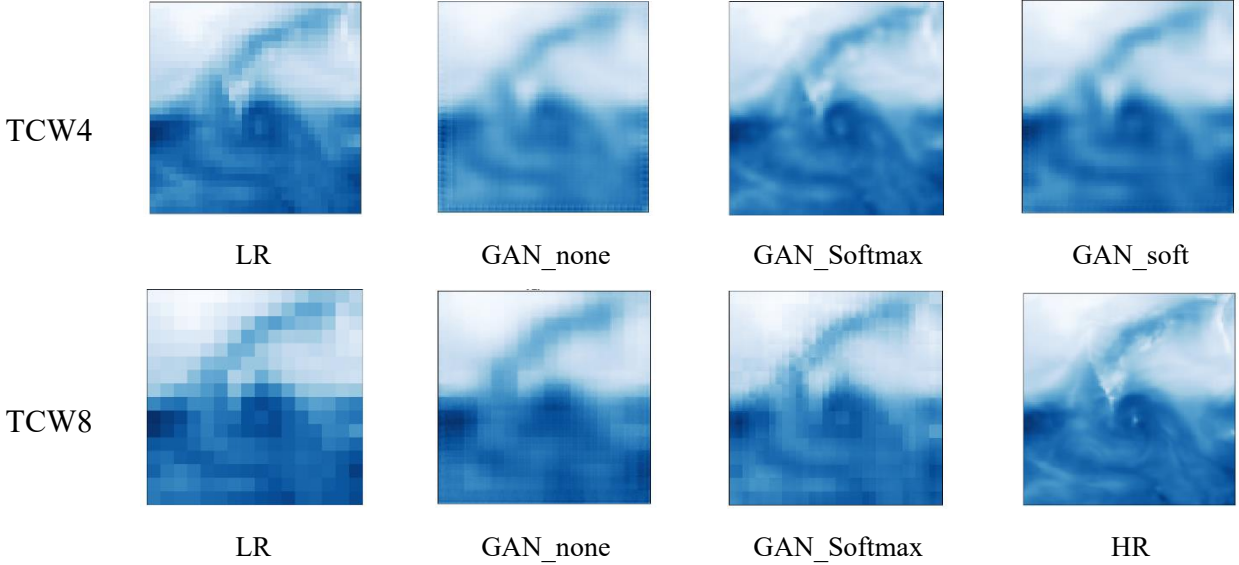


图 8 GAN 相关的实验结果（选取数据集中特定帧展示）

综合以上 12 组实验结果可以得出以下结论：引入物理一致性约束（本次实践主要探索的是 Softmax 强约束）能够在多数情境下显著提升模型性能，改善重建图像的物理合理性与数值精度，但具体效果仍依赖于模型结构与任务复杂度的匹配程度。在 CNN 模型中，Softmax 约束在低倍率（TCW2）下性能下降，但在高倍率任务（TCW4）中却极大提升了 PSNR、SSIM 等指标，初步说明此类约束更适用于较高分辨率的重建场景。在 ConvGRU 中，单帧超分建模与物理约束形成良好协同，Softmax 约束下模型各项指标均优于无约束版本；而 Soft 软约束则表现出不稳定性，强调了强约束在序列建模任务中的优势。对于 GAN 模型，Soft 与 Softmax 均有助于提升重构质量，其中 Softmax 约束在各项指标上全面领先，甚至在高放大倍数（TCW8）下仍能显著减少负值像素与 CRPS 误差，表现出极强的稳健性与泛化能力。

#### 2.3.4 约束对 FlowConvGRU 的影响分析

引入 Softmax 物理一致性约束后，模型性能得到了显著提升。FlowConvGRU\_T1\_softmax 模型在均方误差和 平均绝对误差上分别降至 0.6842 和 0.3643，远低于未加约束的 FlowConvGRU\_T1\_none 模型的 476.15 和 16.761，表明预测更加精确。此外，PSNR 从 13.201 提升至 41.627，说明图像重建质量大幅提高；SSIM 也从 0.181 上升至 0.978，反映出预测图像在结构和纹理方面更接近真实图像。最为关键的是，加入 Softmax 约束后，负值像素数为 0，而无约束模型中负值多达 1057907 个，体现了物理一致性约束在提升预测合理性和物理可解释性方面的必要性。

该实验改善效果优于以上对比实验中的任意一个实验，可能预示着引入时序信息之后，模型对接近现实情境的要求更高了，没有约束的情况下不符合物理可解释性，在模型引入时序信息后导致预测成为灾难。引入 Softmax 约束前后，模型降尺度效果的可视化图像如图 9、10 所示。

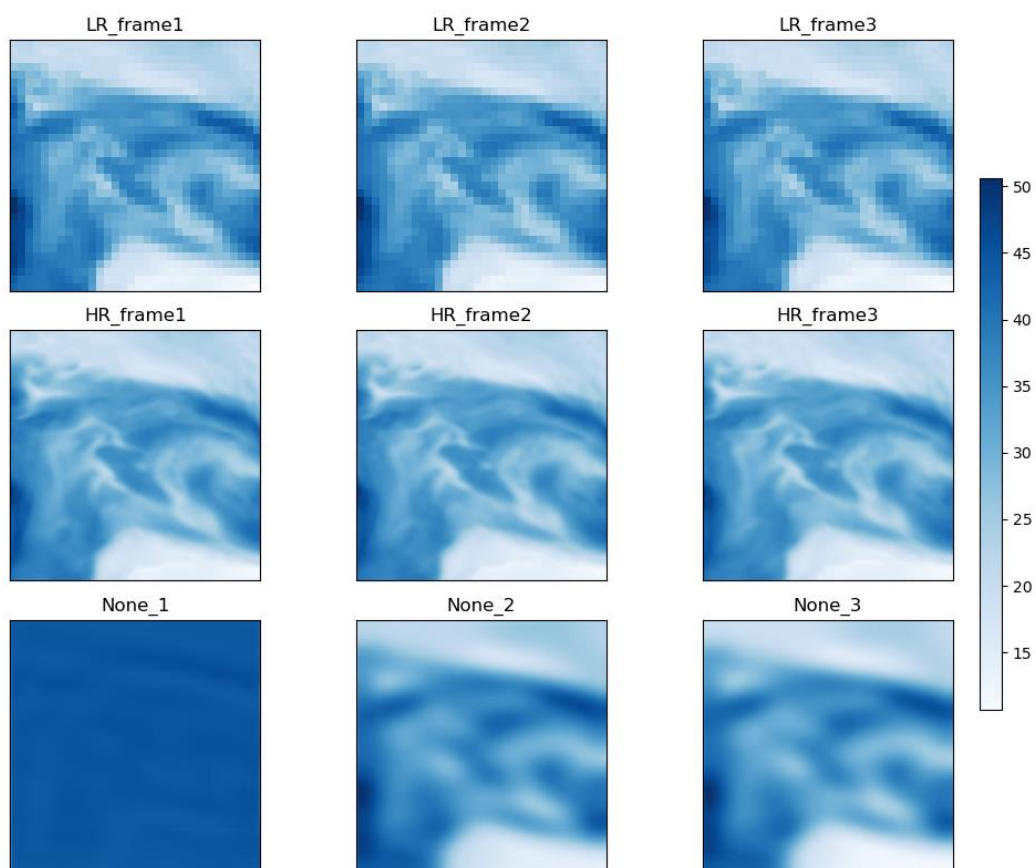


图 9 不加约束的预测结果

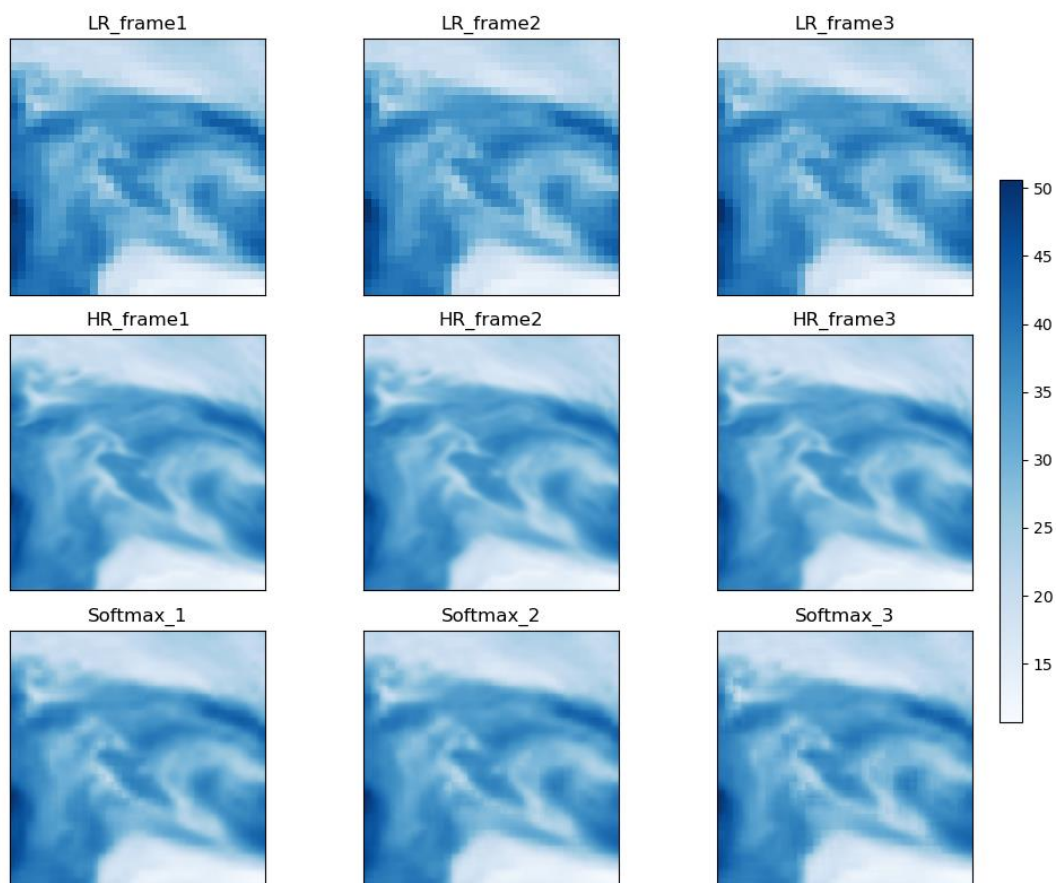


图 10 加入 Softmax 约束的预测结果



### 3. 总结和展望

本次实践，我验证了利用高低分辨率遥感数据训练深度学习模型，可以有效将气象场的空间分辨率提升 2-8 倍，且通过融入物理约束进一步提高了结果的可信度。然而，气象遥感数据降尺度作为一个跨“大数据”和“大气科学”的交叉课题，仍有诸多技术挑战和未来发展方向需要深入探索：

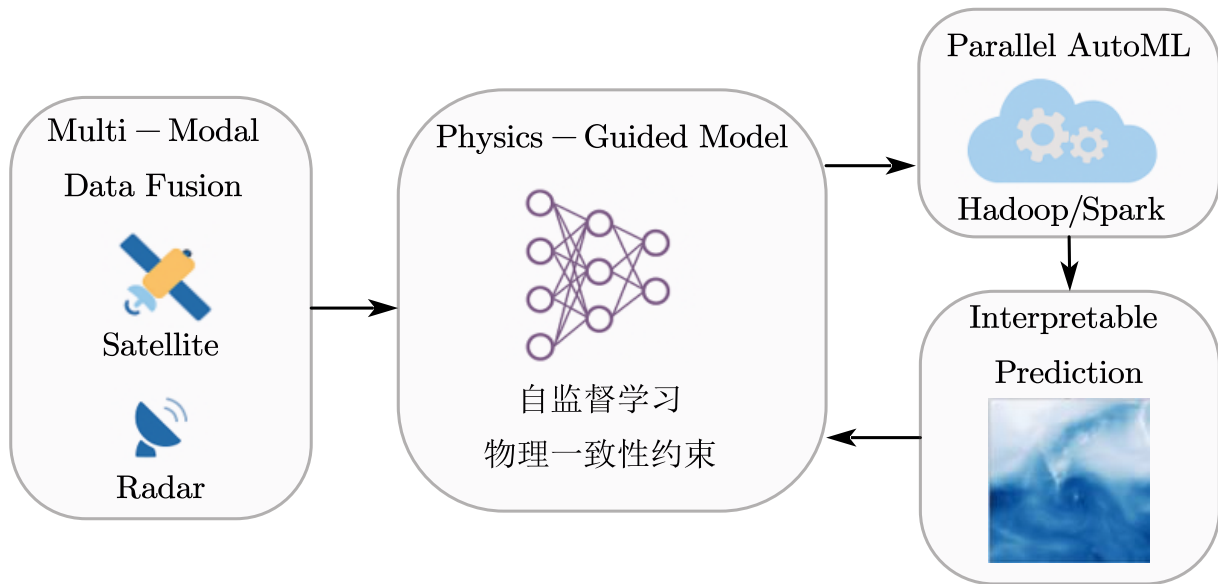


图 11 未来气象降尺度深度学习框架设想图

- (1) 强化物理一致性与可解释性：未来的降尺度模型应当更严格地遵循大气物理定律。例如，在模型结构中硬编码守恒约束或引入基于动力方程的正则项，确保如降水总量、流体连续性等宏观量守恒。同时，可借鉴可解释人工智能的方法，分析模型内部特征对物理过程的对应关系，提升模型对气象现象的解释能力。这将增强降尺度结果在科研和业务中的信任度。
- (2) 多源遥感与多模态数据融合：单一数据源的信息往往有限，未来可将多源数据融合用于降尺度模型训练与推理。例如将卫星可见光、红外、微波探测的数据结合数值模式再分析场，共同作为模型输入，以提供更丰富的特征。多模态数据的融合有望提升模型对不同天气条件的适应性，实现“1+1>2”的效果。同时，可以考虑多变量联动降尺度，即利用温度、湿度、风场等变量的相关性，通过多任务学习同时下尺度多个变量。这不仅可提高单变量的重建精度，也能确保不同气象要素之间的物理一致性。
- (3) 模型轻量化与边缘部署：当前深度超分模型参数量大、计算量高，限制了其实时应用。未来需要在模型优化和工程实现上下功夫，例如采用模型压缩、知识蒸馏和高效卷积算子等技术，将模型体积和推理延迟显著降低。同时，可针对移动端和边缘设备（如星载处理器、野外自动站等）的算力特点进行裁剪，开发小而精的降尺度网络。这将使高分辨率气象预报和监测在资源受限环境下成为可能。
- (4) 复杂场景与极端事件处理：在气候变化背景下，极端天气事件频发。降尺度模型需要能准确刻画极端值和罕见现象，如超级暴雨的中心强度、小尺度龙卷等。这可能需要在损失函数中加入对极端误差的特殊关照（例如采用基于极值理论的损失项），或通过生成对抗训练进一步放大模型对罕见事件的学习能力。此外，还需针对不同下垫面（城市、山地、海洋）和不同气候带定制或自适应调整模型，以应对各种复杂场景下的降尺度需求。

气象遥感数据降尺度正朝着更高分辨率、更高物理可信度和更广应用范围的方向发展。未来的研究将更加注重将大数据技术与大气物理知识深度融合，利用先进的深度学习算法提升空间分辨率的同时，确保结果符合大气科学规律并具有业务实用价值，为应对气候变化和减灾防灾提供强有力的技术支撑。

## 4. 附录

本次实践得到的图片一览（配套我的实验设计）



cnn\_no\_2.png



cnn\_no\_4.png



cnn\_sm\_2.png



cnn\_sm\_4.png



conv\_no\_4.png



conv\_sm\_4.png



conv\_soft\_4.png



gan\_no\_4.png



gan\_no\_8.png



gan\_sm\_4.png



gan\_sm\_8.png



gan\_soft\_4.png

training 以及 evalonly 得到的文件一览（配套我的实验设计）

```
t1_convgru_noconstraints.pth
t1_convgru_softmaxconstraints.pth
tcw4_convgru_noconstraints.pth
tcw4_convgru_softmaxconstraints.pth
twc2_cnn_noconstraints.pth
twc2_cnn_softmaxconstraints.pth
twc4_cnn_noconstraints.pth
twc4_cnn_softmaxconstraints.pth
twc4_gan_addconstraints.pth
twc4_gan_noconstraints.pth
twc4_gan_softconstraints.pth
twc4_gan_softmaxconstraints.pth
twc8_cnn_softmaxconstraints.pth
twc8_gan_noconstraints.pth
```

```
T1_t1_convgru_noconstraints_val.pt
T1_t1_convgru_softmaxconstraints_val.pt
TCW2_twc2_cnn_noconstraints_val.pt
TCW2_twc2_cnn_softmaxconstraints_val.pt
TCW4_tcw4_convgru_noconstraints_val.pt
TCW4_tcw4_convgru_softmaxconstraints_val.pt
TCW4_twc4_cnn_noconstraints_val.pt
TCW4_twc4_cnn_softmaxconstraints_val.pt
TCW4_twc4_gan_addconstraints_val_ensemble.pt
TCW4_twc4_gan_noconstraints_val_ensemble.pt
TCW4_twc4_gan_softconstraints_val_ensemble.pt
TCW4_twc4_gan_softmaxconstraints_val_ensemble.pt
TCW8_twc8_gan_noconstraints_val_ensemble.pt
TCW8_twc8_gan_softmaxconstraints_val_ensemble.pt
```

部分实验过程（训练、评估）

```
#params: 505346
#params discr.: 286561
O:\Anaconda\lib\site-packages\torch\nn\modules\conv.py:456: UserWarning: Plan failed with a cudnnException: CUDNN_BACKEND_EXECUTION_PLAN_DESCRIPTOR: cudnnFinalize Descriptor Fail
  return F.conv2d(input, weight, bias, self.stride,
O:\Anaconda\lib\site-packages\torch\autograd\graph.py:744: UserWarning: Plan failed with a cudnnException: CUDNN_BACKEND_EXECUTION_PLAN_DESCRIPTOR: cudnnFinalize Descriptor Fail
  return Variable._execution_engine.run_backward( # Calls into the C++ engine to run the backward pass
Epoch 1, Train Loss: 0.00017, Discr. Loss2.46453,time:4.14643 s
Val loss: 0.00015,time:0.28195 s
Epoch 2, Train Loss: 0.00017, Discr. Loss2.46443,time:3.23404 s
Val loss: 0.00014,time:0.27203 s
Epoch 3, Train Loss: 0.00016, Discr. Loss2.46372,time:3.25406 s
Val loss: 0.00013,time:0.25229 s
Epoch 4, Train Loss: 0.00014, Discr. Loss2.46268,time:3.25781 s
Val loss: 0.00012,time:0.26651 s
Epoch 5, Train Loss: 0.00013, Discr. Loss2.46208,time:3.25754 s
Val loss: 0.00011,time:0.24924 s
Epoch 6, Train Loss: 0.00013, Discr. Loss2.46407,time:3.25842 s
Val loss: 0.00010,time:0.26069 s
```

补充实验（GAN\_TCW4\_add）

指标名称				数值
数据集				TCW4
模型类型				GAN
模型 ID				twc4_gan_addconstraints
上采样倍数				×4
约束类型				Add（加性守恒约束）
MSE				0.1776
RMSE				0.4214
PSNR (dB)				47.60
MAE				0.2127
SSIM				0.9909
MS-SSIM				0.9963
Pearson 相关系数				0.9975
Mean Bias				-9.67e-10
Mean Abs Bias				2.33e-08
Mass Violation				7.10e-07
负值像素均值				-0.00013
负值像素个数				13
CRPS				0.1070
模型策略	MSE↓	PSNR↑	SSIM↑	CRPS↓
GAN + Soft	0.9375	40.37	0.9634	0.3564
GAN + Softmax	0.2002	47.08	0.9896	0.1149
GAN + Add 约束	0.1776	47.60	0.9909	0.1070

x1

y1

y\_pred



[yururu GitHub](#) (项目已托管到 github, 点击查看)